



# Pruebas y Análisis de Resultados - Simulación NS3

## Integrantes

Fabio Steven Tovar Ramos

## Fecha de entrega

17 de junio del 2020

## Contenido

Descripción del problema	2
<b>Ambiente de entrenamiento</b>	<b>2</b>
Agente binario	2
Agente cognitivo	4
<b>Ambiente real</b>	<b>5</b>
Agente binario	5
Agente cognitivo	6
<b>Comparación de rendimiento</b>	<b>6</b>
<b>Conclusiones</b>	<b>8</b>

## 1. Descripción del problema

Generar una red ad hoc de mínimo 20 nodos, con diferentes tipos de tráfico y servicios en NS3. También se debe utilizar la herramienta Open AI-Gym definiendo un ambiente multiagente con mínimo dos agentes que hagan uso de al menos dos métricas de aprendizaje para definir su comportamiento.

Comparar los resultados, y generar el informe técnico y la descripción del código.

## 2. Ambiente de entrenamiento

Se generaron dos ambientes en la solución de este problema, un ambiente de entrenamiento y un ambiente real. Sin embargo, como es deseable que los modelos tengan un rendimiento bueno en el ambiente real, los dos ambientes son idénticos en cuanto a su funcionamiento. Su única diferencia radica en que en el ambiente de entrenamiento solo interactúa el agente binario con el ambiente de la simulación, se encarga de recolectar datos, guardarlos y enviarlos al agente cognitivo para que aprenda de sus errores y aciertos.

A continuación se hablará acerca del desempeño de ambos en esta fase de la simulación.

### Agente binario

El agente binario se ejecutó sobre 10 ambientes con comportamientos de sus agentes distintos en lo que respecta a posiciones iniciales y movimiento al paso del tiempo. Para cada ambiente se recolectaron datos de aproximadamente 20 minutos de simulación, es decir esperando que los nodos se movieran en promedio 30 veces.

En la figura 1 pueden observarse los datos que describe el comportamiento que tuvo el agente para esta configuración determinada. En el documento del informe técnico podrá encontrar también algunos elementos de la analítica de datos que se usaron para el diseño del agente cognitivo.




Fig. 1. Relación entre poder, radio y distancia

Los datos recolectados fueron más de mil, y se encuentran resumidos en la figura 2. Aquí es importante destacar que los casos límite del problema se concretaron, lo cual es importante si se desea que el agente cognitivo los pueda tener presentes y actúe bien en el caso de concretarse, que son

cuando la distancia entre los nodos emisor y receptor evaluados es mínima, en este caso 0.003907 metros, y cuando la distancia entre ellos es máxima, es decir con una distancia de 4.5 metros.

También se ve como el radio oscila entre 0.4 y 3.9 que es también el comportamiento esperado para la configuración general de los nodos y que muestra que las simulaciones que se ejecutaron fueron suficientes.

	time	radio	reward	distance	power
count	1112.000000	1112.000000	1112.0	1112.000000	1112.000000
mean	24.959532	2.741855	1.0	1.908818	20.825540
std	14.379490	0.661811	0.0	1.001416	8.198931
min	0.000000	0.417234	1.0	0.003907	10.000000
25%	13.000000	2.547950	1.0	1.185962	13.000000
50%	25.000000	2.866986	1.0	1.786633	20.000000
75%	38.000000	3.175110	1.0	2.553610	27.000000
max	49.000000	3.910150	1.0	4.661030	48.000000

Fig. 2. Resumen de los datos recolectados

También cabe resaltar que para niveles de poder menores a 10 no se obtuvo nunca una recompensa positiva por parte del simulador, también que el poder máximo fue de 48, lo que establece claros límites para la solución del problema. También se ve en la figura 3 que la distribución de niveles de poder está fuertemente sesgada hacia la izquierda, mostrando también que posiblemente podrá verse el agente cognitivo sesgado debido a lo desbalanceados que están los datos.

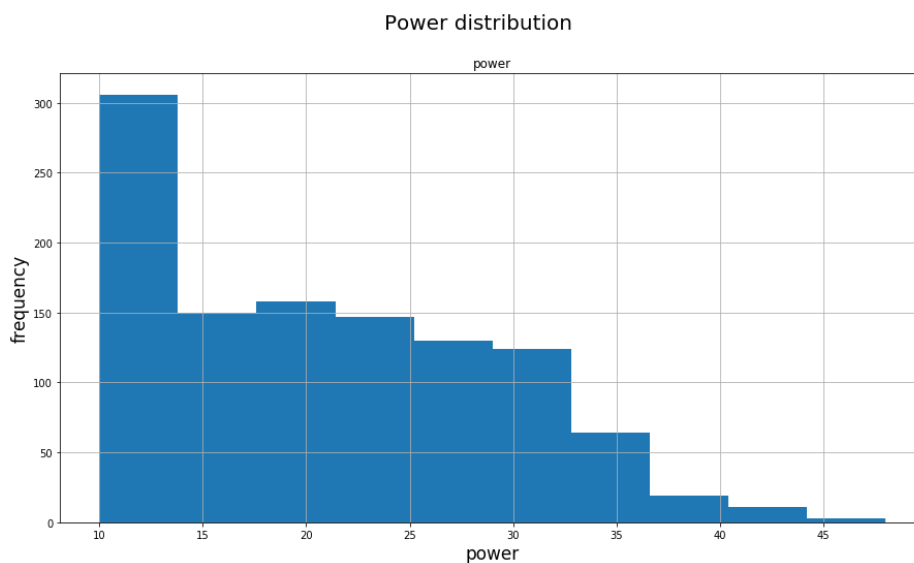


Fig. 3. Distribución de los niveles óptimos de poder

Por último, en la figura 4 se puede validar que los nodos se están moviendo de acuerdo a lo esperado, es decir, que a medida que crece el tiempo, el radio tiende a hacerse más grande, con muy pocas

variaciones para los primeros pasos. Esto debido a la pequeña velocidad de los agentes y el poco tiempo que dura cada uno de sus movimientos.

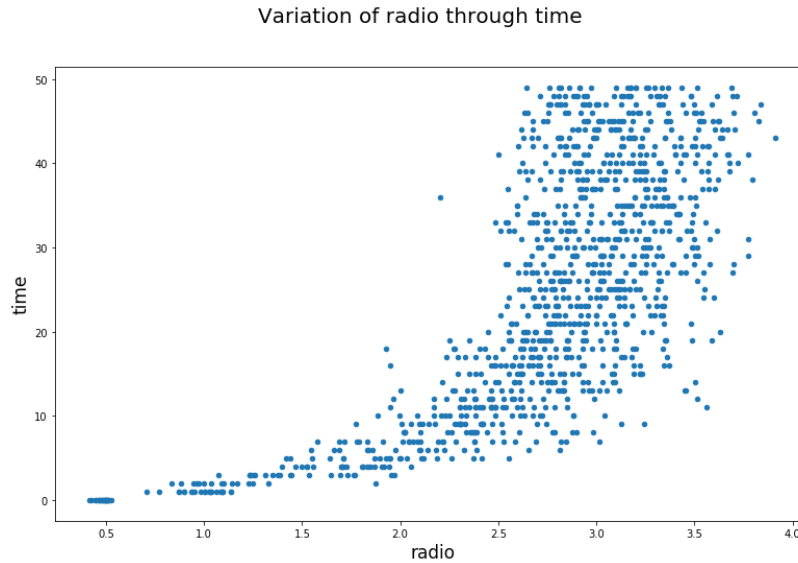


Fig. 4. Variación del radio a través del tiempo

## Agente cognitivo

Con respecto al desempeño del agente cognitivo en el ambiente de pruebas, se mostrará el desempeño del mismo en cuanto al aprendizaje que hizo sobre las características seleccionadas (radio, tiempo, distancia entre nodos) y cómo se ajustó a una serie de datos desconocidos para él.

En primer lugar, se obtuvo un aprendizaje bastante bueno, el cual fue refinado gracias a las técnicas de procesamiento y de limpieza de los datos que se aplicaron antes del entrenamiento. Como se puede observar en la figura 5, se tomaron dos métricas para evaluar el aprendizaje: El error absoluto medio (MAE), y el error cuadrático medio (MSE).

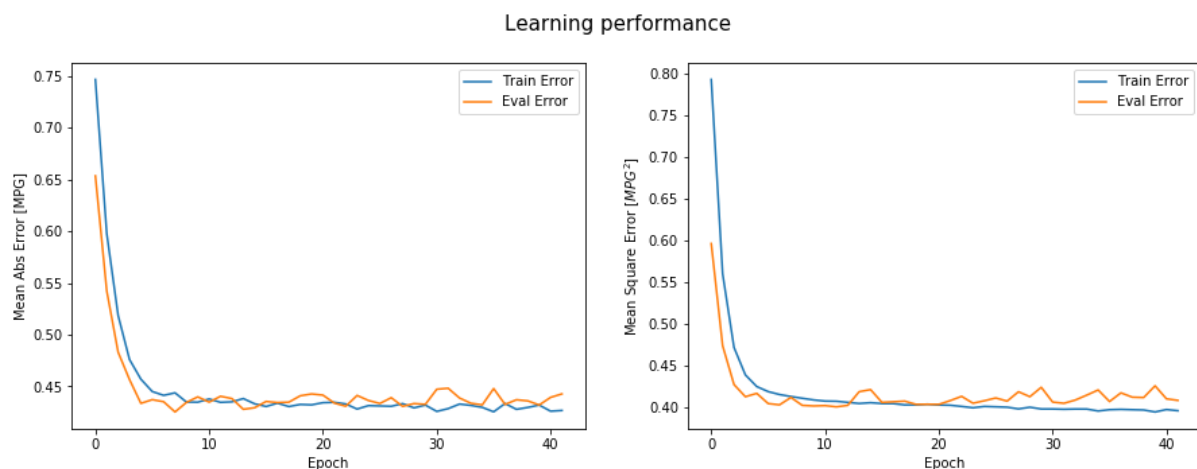


Fig. 5. Comportamiento del agente en su aprendizaje

Se resalta de estas gráficas lo rápido que convergen los modelos hacia un valor estable, puesto a que luego de 20 epochs ambas métricas se encuentran estabilizadas casi que por completo, lo cual es un buen indicador en el momento en el que el agente se quiera re entrenar en un ambiente real.

También se puede corroborar el correcto aprendizaje realizado, el cual se ve en la mínima distancia entre la gráfica del error en los datos de prueba con los datos de entrenamiento, y claramente un último punto muy importante a resaltar es lo pequeños que son los errores para estas predicciones.

Ahora, en la figura 6 se ven los resultados que obtuvo el agente al realizar predicciones con datos nuevos, donde las conjeturas realizadas anteriormente son corroboradas, mostrando un excelente aprendizaje que se ve en lo ajustadas que están las predicciones con respecto a los datos reales.




Figura 6. Desempeño del agente sobre datos desconocidos.

### 3. Ambiente real

En el ambiente real se colocan a competir a ambos agentes, se ejecuta una simulación que se detendrá en el momento en el que un límite de movimientos haya sido realizado por el grupo de agentes y se intenta ver cómo se comportan ambos agentes dadas estas restricciones.

Dado el costo computacional de la anterior tarea, se realiza hasta un límite de 44 movimientos para ambos agentes. Se recuerda que el movimiento de cada grupo de agentes se realiza cada 35 segundos aproximadamente, y en el lapso en el cual están estáticos envían aproximadamente 7 paquetes, lo cual da un total de más de diez mil paquetes enviados para este caso.

#### Agente binario

Los datos obtenidos por la simulación en la cual el agente binario es quien controla los niveles de poder de la red wifi de los nodos están resumidos en la figura 7. Aquí se puede notar que en promedio el nivel de poder requerido por los nodos fue de 3344, este poder es el poder acumulado, es decir la suma de los poderes enviados en cada paso del simulador.

También cabe destacar que en promedio se recibieron 121 paquetes en cada una de las 44 simulaciones, y para dar una mejor idea del rendimiento del agente, se tiene que la tasa de paquetes recibido promedio fue del 72%, lo cual muestra un aparente buen rendimiento, pero que para ser el determinante de la confiabilidad en una red de comunicación es un poco preocupante.

	nodes_movements	packet	packet_rate	accumulated_power
<b>count</b>	44.000000	44.000000	44.000000	44.000000
<b>mean</b>	22.931818	121.954545	0.720621	3344.363636
<b>std</b>	13.277709	68.742511	0.047990	2090.793942
<b>min</b>	1.000000	7.000000	0.648352	133.000000
<b>25%</b>	11.750000	60.500000	0.691824	1475.750000
<b>50%</b>	22.500000	124.500000	0.717738	3372.000000
<b>75%</b>	34.250000	182.250000	0.738448	5168.250000
<b>max</b>	45.000000	236.000000	0.875000	7101.000000

Fig. 7. Resumen de los datos obtenidos por el agente binario

### Agente cognitivo

Como se esperaba el comportamiento del agente binario fue mucho mejor en cuanto a la tasa de paquetes recibidos así como se ve en la figura 8. En promedio el agente cognitivo tuvo 51 paquetes más en cada una de las simulaciones, lo cual muestra un mejor desempeño.

En cuanto a la tasa de paquetes recibidos, se tiene un 99.9% de efectividad, lo cual muestra un rendimiento bastante bueno, y muy deseable, con valores mínimos de 98.7% de rendimiento en el peor de los casos y con un 100% en el mejor. También se ve que en los diferentes percentiles se obtuvo una tasa de 100%, lo cual indica también que el valor mínimo fue bastante atípico.

	nodes_movements	packet	packet_rate	accumulated_power
<b>count</b>	44.000000	44.000000	44.000000	44.000000
<b>mean</b>	22.931818	172.545455	0.999241	15222.613636
<b>std</b>	13.277709	99.440167	0.002276	12192.337722
<b>min</b>	1.000000	8.000000	0.987552	237.000000
<b>25%</b>	11.750000	89.000000	1.000000	4458.750000
<b>50%</b>	22.500000	169.500000	1.000000	12221.500000
<b>75%</b>	34.250000	257.500000	1.000000	24767.750000
<b>max</b>	45.000000	337.000000	1.000000	39817.000000

Fig. 8. Resumen de los datos obtenidos por el agente cognitivo

## 4. Comparación de rendimiento

Se comparará el rendimiento de los agentes más concretamente en las dos características más importantes, el poder acumulado y la tasa de paquetes recibidos.

En la figura 9 se ve como la conjetura que se hizo acerca de la distribución de la tasa de paquetes recibidos en la anterior era cierta. El agente cognitivo presenta un rendimiento excepcional con respecto al agente binario, el cual concentra sus tasas de recepción entre el 70% y el 75%, con un dato atípico que alcanza a estar cerca al 90%.

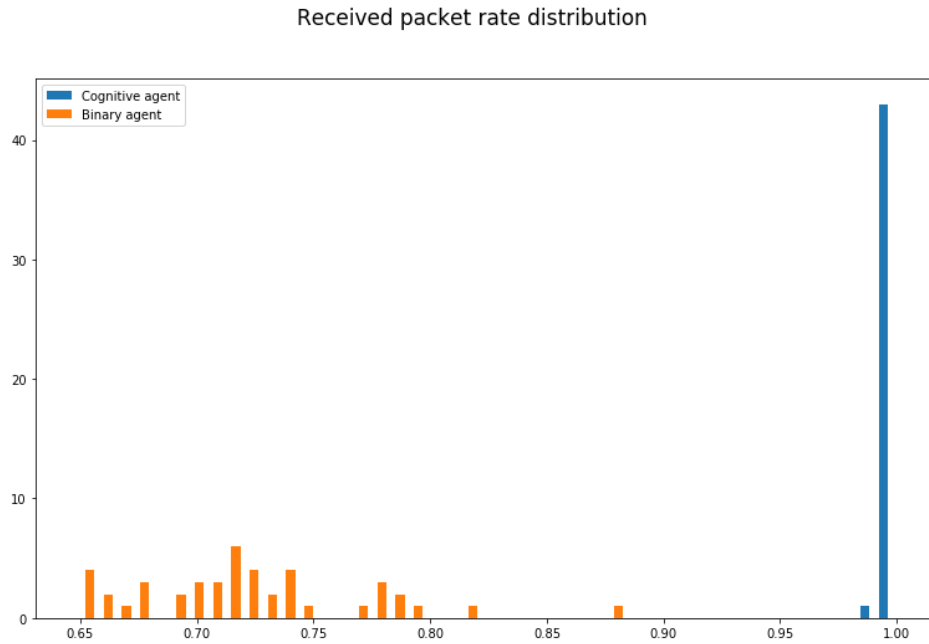


Fig. 9. Tasa de paquetes recibidos para el agente cognitivo y el agente binario

Sin embargo, comparando el poder acumulado con el anterior agente hay una diferencia muy significativa, puesto que en promedio predijo valores 5 veces más grandes que el agente binario. La explicación de esto tiene que ver con la manera del accionar del agente binario, el cual calcula niveles de energía bastante bajos en varios casos debido a la búsqueda binaria que realiza.

El agente binario tiene un mejor desempeño, puesto que se mantiene con un crecimiento mínimo a medida que los agentes se mueven. Por otro lado, el agente cognitivo presenta un poder acumulado con una relación cercana a la lineal, lo cual es indeseable en muchas ocasiones, pero que para este caso tiene bastante sentido, ya que la cantidad de movimientos permitidos aumenta linealmente. Lo anteriormente descrito puede evidenciarse con claridad en la figura 9.

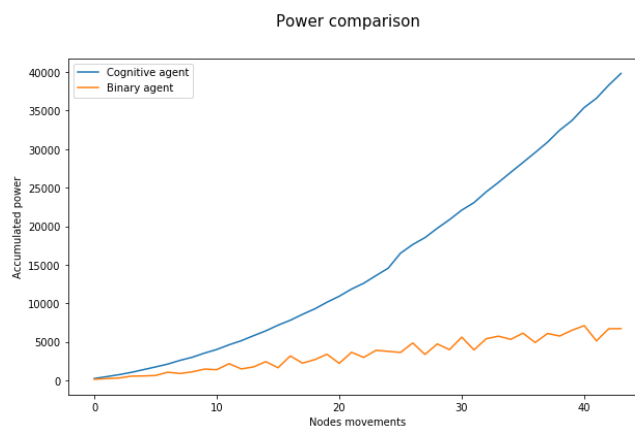


Fig. 9. Poder acumulado usado por el agente binario con respecto al del agente inteligente.



Por último, se presentan las siguientes matrices que muestran cómo se comportan cada par de variables en el comportamiento del agente cognitivo y del agente binario para este ambiente.

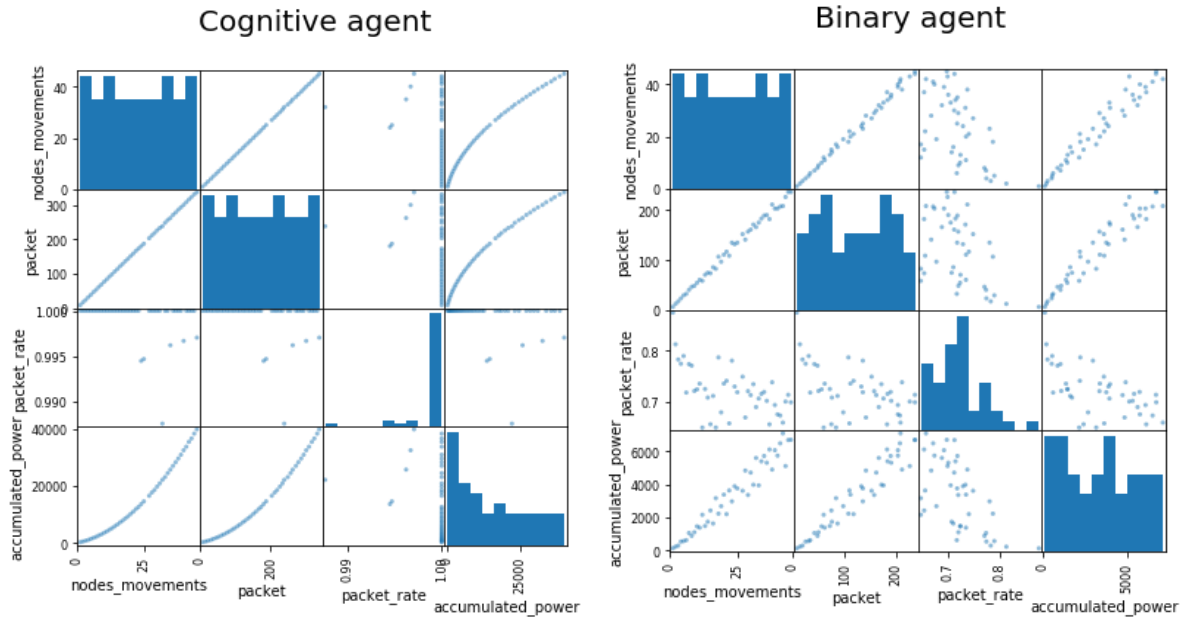


Fig. 10. Matriz de correlación entre variables para el agente cognitivo y binario respectivamente.

## 5. Conclusiones

El aprendizaje de máquina es una herramienta muy poderosa que permite simplificar muchas tareas de una manera muy adecuada, y aunque en muchos casos sus requerimientos sean un poco extensivos, vale la pena tenerla muy en cuenta.

Es importante también ver cómo mediante la inteligencia artificial pueden obtenerse modelos que actúan bien en ambientes estocásticos, como lo es la simulación de una red de nodos moviéndose de maneras no determinísticas, y viendo cómo mediante diferentes técnicas se pueden resolver problemas similares.

Por último es de resaltar el desarrollo de NS3 y NS3Gym, puesto que expone una interfaz sencilla para que los científicos de telecomunicaciones y de redes puedan realizar un sinnúmero de estudios ayudados con el sinnúmero de herramientas que ofrecen lenguajes de programación como python, que ayudan a las personas a plasmar ideas de manera muy sencilla y rápida. Sin embargo, quizá es necesario popularizar más el uso de estas herramientas para poder generar una comunidad más grande, que permita tener más documentación y que así, la curva de aprendizaje sea un poco menos pronunciada.